

— Занятие 1

Excel как среда анализа данных

Загрузка и типы данных

02

Результат занятия

После сегодняшнего семинара вы:

01

Различаете типы признаков

количественный, порядковый, номинальный — и что с каждым можно делать

02

Загружаете CSV

с корректной кодировкой, разделителями и типами

03

Работаете с таблицей

именованный объект вместо набора координат


04

Диагностируете типы

находите и исправляете дефекты данных

Что такое анализ данных

Анализ данных — это путь от вопроса к обоснованному решению



Что из этого делает аналитик

- Переводит расплывчатый вопрос заказчика в вопрос, на который данные могут ответить
- Проверяет, что данные вообще пригодны для этого вопроса
- Выбирает метод, соответствующий типу данных и вопросу
- Формулирует вывод так, чтобы на его основе можно было действовать

Цикл анализа данных

1

Вопрос

что именно нужно узнать и кто примет решение

2

Сбор и загрузка

откуда данные, в каком формате, за какой период

3

Очистка и проверка

типы, пропуски, дубликаты, выбросы

4

Разведочный анализ

распределения, срезы, связи между признаками

5

Моделирование

формальная зависимость и ее проверка

6

Интерпретация

вывод на языке заказчика, а не на языке метода

Вопросы к данным

Что произошло?

Описание: сколько, где, у кого.
Частоты, сводные таблицы,
графики

Почему?

Диагностика: с чем связано.
Сравнение групп, корреляция

Что будет?

Прогноз: как зависит и что
ожидать. Регрессия

Что делать?

Решение принимает человек,
данные только сужают выбор

Из чего состоят данные

Наблюдение

один объект, о котором собраны сведения: заказ, клиент, день, квартира

Признак

одно измеряемое свойство объекта: цена, город, дата, статус

Значение

то, что признак принимает у конкретного наблюдения

Анализ данных — это поиск закономерностей в том, как значения одних признаков меняются вместе со значениями других.

Как должны быть устроены данные


один столбец — один признак

Дата	Клиент	Товар	Сумма
01.03.2024	ООО «Альфа»	Стол	12 400
01.03.2024	ИП Петров	Стул	3 200
02.03.2024	ООО «Бета»	Лампа	1 850


— одна строка —
одно наблюдение

Ни объединенных ячеек, ни подзаголовков внутри таблицы, ни единиц измерения в соседней колонке

Типы признаков



Типы признаков



Количественные признаки

значение получено счетом или измерением

Дискретный

Результат счета. Значения можно перечислить, между соседними ничего нет.

Число заказов · количество комнат · число визитов

Непрерывный

Результат измерения. Между любыми двумя значениями есть третье, точность ограничена только прибором.

Цена · площадь · время доставки · вес

И те и другие можно складывать, вычитать, усреднять. Для них осмысленны среднее, медиана, стандартное отклонение, гистограмма и диаграмма рассеяния.

Категориальные признаки

значение — принадлежность к группе

Номинальный

Порядка нет, категории равноправны.

Город · товар · канал продаж · пол

Порядковый

Порядок есть, расстояние между соседними неизвестно.

Оценка · уровень · размер S/M/L

Бинарный

Две категории — частный случай номинального.

Вернул / не вернул · да / нет

Усреднять категории нельзя. Считаем частоты, доли и моду; сравниваем группы между собой.

Тип признака определяет метод

Тип признака	Статистика	График
Количественный	среднее, медиана, разброс	гистограмма, ящик с усами
Категориальный	частоты, доли, мода	столбчатая диаграмма
Два количественных	корреляция, регрессия	диаграмма рассеяния
Категор. × количеств.	статистики по группам	сравнение групп
Дата и время	динамика, периоды	линейный график

Число — еще не количественный признак

190 000

почтовый индекс

номинальный

78

код региона

номинальный

4517

номер клиента

номинальный


4 из 5

оценка товара

порядковый

Средний почтовый индекс, средний код региона и средний номер клиента — числа, которые Excel посчитает без ошибки и которые ничего не значат.

Импорт CSV



Что проверить в окне предпросмотра

Кодировка

UTF-8 — иначе кириллица превратится в мусор

Разделитель

запятая, точка с запятой или табуляция

Десятичный разделитель

точка или запятая — от этого зависит, число это или текст

Локаль источника

порядок дня и месяца в датах

Две кнопки в окне импорта

«Преобразовать данные»

Открывает редактор Power Query. Типы, лишние столбцы и мусорные строки чинятся до того, как данные попадут на лист. Все шаги сохраняются и повторяются на новом файле.

«Загрузить»

Данные сразу оказываются на листе с тем, как их понял Excel. Быстро — и приемлемо только когда файл заведомо чистый.

Двойной щелчок по CSV

почему так делать нельзя

~~00712~~ → 712

ведущие нули артикула потеряны

~~10-15~~ → 15 окт

диапазон превратился в дату

~~1.5~~ → 1 мая

на локали с запятой — тоже дата

Excel угадывает типы в момент открытия и не спрашивает. Исходное значение уже не восстановить — только перезагрузить файл правильно.

Умная таблица

`Ctrl+T` (CMD+T) превращает диапазон в объект

Имя

к таблице можно обращаться по имени, а не по адресу диапазона

Расширение

новая строка автоматически попадает во все формулы и сводные

Строка итогов

агрегаты одним переключателем, с учетом фильтра

Автофильтр

и заголовки, закрепленные при прокрутке

Структурированные ссылки

```
= Продажи[@Цена] * Продажи[@Количество]
```

Формула читается как действие над столбцами, а не над клетками. Скопированная в другое место, она остается верной — потому что ссылается на имя, а не на координату.

Excel

```
Продажи[@Цена]
```

pandas

```
df['Цена']
```

Таблица — это именованный объект с именованными столбцами, то есть тот же DataFrame.

Загрузить учебный датасет

- 01 Импортировать файл через Данные → Из текста/CSV
- 02 Зафиксировать число строк и число столбцов
- 03 Добавить строку итогов

Четыре типа хранения в Excel

Число

выравнивается вправо;
даты и время — тоже
числа

Текст

выравнивается влево; в
арифметике дает
ошибку

Логическое

ИСТИНА / ЛОЖЬ; в
вычислениях ведет себя
как 1 и 0

Ошибка

#Н/Д, #ДЕЛ/0!, #ЗНАЧ! —
тоже значение, и его
надо ловить

Выравнивание по умолчанию — бесплатный индикатор типа. Число, прижатое влево, почти всегда текст.

Дата — это число

Excel считает дни от 1 января 1900 года. Целая часть — дата, дробная — время.

01.01.1900 = 1

15.03.2024 = 45 366

15.03.2024 12:00 = 45 366,5

Отсюда следуют две вещи:

даты можно вычитать и получать число дней;

дата, прочитанная как текст, не будет ни сортироваться, ни группироваться по месяцам.

Проверить и преобразовать

Проверить тип	
ЕЧИСЛО	значение — число
ЕТЕКСТ	значение — текст
ЕПУСТО	ячейка пуста
ЕОШИБКА	значение — ошибка
ТИП	код типа числом

Преобразовать	
ЗНАЧЕН	текст → число
ДАТАЗНАЧ	текст → дата
ТЕКСТ	число → текст в нужном формате

Диагностику удобно вынести на отдельный служебный лист: столбец — признак, строка — проверка.

Типовые дефекты выгрузок

Числа как текст

зеленый маркер в углу ячейки;
суммируются в ноль, сортируются
по алфавиту

Неразрывные пробелы

приходят из веб-выгрузок;
обычный СЖПРОБЕЛЫ их не
убирает

Ведущие нули

артикулы и коды теряют нули и
перестают совпадать со
справочником

Диагностика и починка типов

- 01 Построить диагностическую таблицу типов по всем столбцам датасета: ТИП + СЧЁТЕСЛИ
- 02 Найти два намеренно «сломанных» столбца
- 03 Починить их: Текст по столбцам, СЖПРОБЕЛЫ + ПОДСТАВИТЬ, Мгновенное заполнение
- 04 Указать для каждого столбца тип признака и тип хранения — и отметить расхождения

Power Query: воспроизводимый пайплайн

01 Панель примененных шагов — вся история преобразований видна и редактируема

02 Изменение типа на этапе загрузки, до попадания данных на лист

03 Переименование и удаление столбцов

04 Обновление одной кнопкой при замене файла-источника